

Avaliação Prática 1 — Classificação de Imagens (CIFAR-10): Respostas

Disciplina: Aprendizagem de Máquina · PPGIA / PUC-PR · Mestrado 2026

Aluno: Fernando Dantas

Reprodutibilidade: todos os valores foram gerados pelos scripts listados na seção *Scripts* (*seed* primária 42); o relatório é regenerado a partir dos artefatos de resultado por [report.py](#).

Protocolo Experimental

Foram avaliadas cinco estratégias de classificação sobre a base **CIFAR-10** (60.000 imagens coloridas de 32×32 pixels, 10 classes balanceadas): (1) CNN treinada do zero; (2) rede pré-treinada como extratora de características, com classificador raso; (3) ajuste fino de CNN pré-treinada na ImageNet; (4) ajuste fino com aumento de dados; e (5) ajuste fino de um *Vision Transformer* (ViT).

Orçamento igual entre estratégias. Todas as estratégias foram treinadas sobre a **mesma subamostra estratificada de 10.000 imagens** (1.000 por classe), validadas sobre as **mesmas 2.000 imagens** e avaliadas **uma única vez** sobre o **conjunto de teste oficial completo do CIFAR-10** (10.000 imagens). A subamostragem não é um atalho, mas a condição de legalidade da comparação: as cinco estratégias diferem em custo computacional por um fator de aproximadamente 50 — uma CNN treinada do zero em 32×32 converge em minutos, enquanto o ajuste fino de um ViT-B/16 em 224×224 não —, e o orçamento disponível (GPU T4, camada gratuita) não comporta a base completa em cinco estratégias, três sementes aleatórias (*seeds*) e quatro ablações. Diante dessa restrição, a escolha se dá entre *todas as estratégias com 10.000 imagens* e *algumas estratégias com mais dados que outras*; apenas a primeira constitui um experimento controlado.

Consequência declarada. Um regime de 10.000 imagens é um regime de poucos dados, e é precisamente nesse regime que a transferência de aprendizado exibe sua maior vantagem. Uma CNN treinada do zero recuperaria parte substancial da diferença com as 50.000 imagens da base completa. As conclusões aqui reportadas referem-se, portanto, à comparação **sob este orçamento de dados**, e não a uma superioridade intrínseca e incondicional das estratégias baseadas em transferência.

Resolução de entrada. As estratégias 2, 3 e 4 operam a **128×128 pixels**, e não aos 224×224 nativos da ImageNet. As imagens do CIFAR-10 têm 32×32 pixels: ampliá-las para 224×224 não acrescenta informação alguma — apenas fabrica pixels por interpolação —, ao custo de aproximadamente três vezes mais computação. A resolução de 128 px ainda representa uma ampliação de 4× sobre a fonte e é um tamanho de entrada oficialmente suportado pela MobileNetV2. A escolha é aplicada de modo idêntico às três estratégias, constituindo, portanto, uma constante controlada da comparação, e não uma variável. A estratégia 5 permanece em 224×224, pois a grade de *patches* e as codificações posicionais do ViT são fixadas pelo checkpoint pré-treinado.

Isolamento do conjunto de teste. A arquitetura, o número de épocas e a parada antecipada foram selecionados exclusivamente sobre o conjunto de validação. O conjunto de teste produziu exatamente

um número por configuração: não houve seleção de época, de limiar ou de configuração com base no teste.

Cobertura experimental. A comparação principal entre estratégias é reportada em **execução única** (*seed* 42), à exceção da Estratégia 3, para a qual há **duas execuções** (*seeds* 42 e 7). A ablação da questão 4(a) dispõe de duas *seeds* por braço; a da questão 2(a), de uma. Essa cobertura desigual decorre da restrição computacional documentada na seção *Limitações do Delineamento*, e é reportada tal como é: **o desvio-padrão é omitido onde não foi medido**, jamais substituído por zero.

A validade das comparações não repousa, contudo, sobre a repetição. Ela repousa sobre o **teste exato de McNemar aplicado a predições pareadas**: como todos os modelos são avaliados sobre as **mesmas** 10.000 imagens, seus erros são pareados por construção, e a evidência é extraída das concordâncias e discordâncias entre eles — não da variância entre execuções. A *seed* altera a inicialização dos pesos e a amostragem do aumento de dados, jamais os dados: a subamostra é fixada por um gerador independente.

Variabilidade entre execuções idênticas. A Estratégia 3, na *seed* 42, foi treinada duas vezes sob configuração rigorosamente idêntica, obtendo **0,8512** e **0,8558**. A diferença de **0,46 ponto percentual** decorre do não-determinismo dos núcleos cuDNN em GPU e fornece uma **estimativa empírica do ruído de treinamento** neste experimento. Trata-se de valor da mesma ordem de grandeza das diferenças que separam as Estratégias 2, 3 e 4, o que estabelece um piso de resolução para qualquer comparação entre elas — e justifica que os vereditos sejam emitidos por teste estatístico pareado, e não por leitura direta das acurácias.

Inferência estatística. Para o par de melhores modelos aplicou-se o **teste exato de McNemar** sobre as predições pareadas do conjunto de teste. Este é o teste adequado ao delineamento — e não o teste de Wilcoxon sobre dobras, empregado na Atividade 1 —, pois ambos os modelos são avaliados sobre **as mesmas** 10.000 imagens: os erros são, por construção, pareados, e apenas as predições discordantes carregam informação. Reporta-se ainda o intervalo de confiança de Wilson (95%) para a acurácia; sobre 10.000 amostras, sua semi-amplitude é de aproximadamente $\pm 0,6$ ponto percentual em torno de 90% de acurácia, o que estabelece o **limite de resolução de qualquer afirmação deste relatório**.

Escopo da comparação. Não houve busca sistemática de hiperparâmetros: as configurações seguem as práticas correntes de cada estratégia (taxas de aprendizado padrão, parada antecipada sobre a acurácia de validação). As conclusões referem-se à comparação dessas configurações, não à superioridade intrínseca dos métodos. As ablações das investigações complementares isolam uma única variável por vez, mantendo dados, cronograma e *seeds* fixos.

Ambiente. Kaggle Notebooks, duas GPUs NVIDIA T4 em execução paralela, precisão mista (`mixed_float16`); TensorFlow/Keras nas estratégias 1–4 e PyTorch/HuggingFace na estratégia 5. Os *splits* são materializados em disco e lidos por ambos os frameworks, o que garante que as estratégias vejam dados byte a byte idênticos independentemente do framework utilizado.

Limitações do Delineamento

Quatro fatores limitam a interpretação dos resultados. Todos são declarados aqui, antes dos resultados, porque nenhum deles é corrigível dentro do orçamento disponível — e um relatório que os omitisse atribuiria a causas erradas os efeitos que observa.

1. O ViT não enfrenta um problema novo. O ViT-B/16 foi pré-treinado na **ImageNet-21k**, cujo conjunto de classes contém categorias que coincidem, em substância, com as do CIFAR-10 — avião, automóvel, pássaro, gato, cervo, cão, sapo, cavalo, navio e caminhão são todas categorias amplamente representadas na ImageNet. O modelo, portanto, **não generaliza para um domínio inédito: ele reconhece categorias que já viu durante o pré-treinamento**, em resolução muito superior e com ordens de magnitude mais exemplos. Sua acurácia deve ser lida como um limite superior de transferência sob condições excepcionalmente favoráveis, e **não** como evidência de superioridade intrínseca da arquitetura *transformer* sobre a convolucional. As redes convolucionais pré-treinadas (estratégias 2 a 4) compartilham essa vantagem, porém em grau menor: foram pré-treinadas na ImageNet-1k, cerca de quatorze vezes menor.

2. A resolução de entrada não é constante entre as estratégias. A CNN treinada do zero opera em 32×32 — a resolução nativa das imagens —, enquanto as demais operam em 128×128 (ou 224×224 , no caso do ViT), pois as redes pré-treinadas exigem entradas compatíveis com suas estatísticas de origem. Essa diferença é **inerente à natureza das estratégias comparadas**, e não um descuido: ampliar as imagens para treinar uma rede do zero apenas interpolaria pixels, sem acrescentar informação, ao custo de mais computação. Ainda assim, ela impede atribuir a diferença de desempenho exclusivamente ao pré-treinamento.

3. Restrição computacional e cobertura desigual. O experimento foi conduzido em infraestrutura de GPU de acesso gratuito, com cota limitada. Em consequência, a comparação principal repousa majoritariamente sobre execução única, ao passo que as ablações dispõem de duas *seeds* por braço. **A estabilidade das estratégias frente à inicialização dos pesos não foi medida, e não é reivindicada;** a inferência é sustentada pelo teste pareado de McNemar, cuja evidência provém das 10.000 predições do conjunto de teste, e pela estimativa de ruído de treinamento apresentada no protocolo.

4. Seleção de modelo interna a cada fase. A parada antecipada seleciona o melhor modelo **dentro** de cada uma das duas fases de treinamento (cabeça congelada; descongelamento do bloco superior), e não **globalmente entre elas**. O delineamento pressupõe, portanto, que a fase 2 aprimore o resultado da fase 1 — pressuposto válido em vinte e seis das vinte e sete execuções de ajuste fino conduzidas, e violado em uma (SGD, *seed* 7), conforme documentado na investigação 4(b). A correção é direta e está registrada como trabalho futuro; sua ausência afeta apenas execuções cuja fase 2 degrada o modelo, e o faz na direção conservadora.

Resultados por Estratégia

Estratégia	Configuração	Acurácia (teste)	IC 95%	Macro-F1	Resolução	Parâmetros treináveis	Treino
5 — Ajuste fino de ViT	vit_base_patch16_224_in21k	0,9825	0,9797–0,9849	0,9825	224px	85.806.346	6,7 min
4 — Ajuste fino + aumento de dados	mobilenetv2_gap_flip_crop	0,8650	0,8582–0,8716	0,8650	128px	2.171.722	8,6 min
3 — Ajuste fino	mobilenetv2_gap	0,8576 ± 0,0025	0,8488–0,8660	0,8575 ± 0,0024	128px	2.171.722	3,3 min
2 — Extração de características	mobilenetv2_svm	0,8522	0,8451–0,8590	0,8524	128px	0	0,6 min
1 — CNN do zero	cnn_scratch	0,7636	0,7552–0,7718	0,7617	32px	305.258	1,7 min

A tabela reporta, ao lado da acurácia, a resolução de entrada, o número de parâmetros treináveis e o tempo de treinamento. Um ranking de acurácia desacompanhado dessas colunas convida o leitor a celebrar uma vantagem de 0,3 ponto percentual que custou cinquenta vezes mais computação e que se encontra dentro do ruído experimental.

Melhor Resultado

Significância estatística da diferença entre o 1º e o 2º colocados

- 1º s5_vit / vit_base_patch16_224_in21k — 0,9825
- 2º s4_augment / mobilenetv2_gap_flip_crop — 0,8650

Discordâncias	1º certo / 2º errado	1º errado / 2º certo	p (McNemar exato)
1311	1243	68	3,234e-280

A diferença de 11,75 pp é **significativa** ($\alpha = 0,05$). O primeiro colocado é, portanto, o melhor modelo desta comparação.

Todas as comparações entre estratégias (McNemar exato, seed primária)

Comparação	Δ	p (McNemar)	Significativa?
Estratégia 2 vs. 1	+8,86 pp	5,7e-83	sim
Estratégia 3 vs. 1	+9,22 pp	8,16e-89	sim
Estratégia 3 vs. 2	+0,36 pp	0,159	não — empate técnico
Estratégia 4 vs. 1	+10,14 pp	2,86e-109	sim
Estratégia 4 vs. 2	+1,28 pp	5,96e-06	sim
Estratégia 4 vs. 3	+0,92 pp	0,000397	sim
Estratégia 5 vs. 1	+21,89 pp	0	sim
Estratégia 5 vs. 2	+13,03 pp	4,74e-322	sim
Estratégia 5 vs. 3	+12,67 pp	6,83e-312	sim
Estratégia 5 vs. 4	+11,75 pp	3,23e-280	sim

Cada linha confronta um incremento de transferência com o anterior. Uma diferença que não sobrevive ao teste de McNemar é uma diferença **paga e não recebida**: o custo computacional foi incorrido, o ganho não se materializou. Essa informação é invisível em um ranking de acurácia.

Achado central: o ajuste fino não supera significativamente a extração de características. Ambas as estratégias compartilham o **mesmo backbone** (MobileNetV2) e a **mesma resolução** (128 px) — o que muda entre elas é exclusivamente o descongelamento do bloco superior. Na seed 42, a Estratégia 3 obtém **0,8558** contra **0,8522** da Estratégia 2: uma diferença de **+0,36 ponto percentual** que o teste exato de McNemar **não distingue de zero** ($p = 0,159$; 327 discordâncias a favor contra 291 contra). **Empate técnico.**

O custo, contudo, não empata: a Estratégia 2 consome **0,6 minuto** de GPU — um único passe direto das 22.000 imagens pela rede congelada, seguido do ajuste de uma SVM —, contra **3,3 minutos** da Estratégia 3. **Cinco vezes mais computação, para um ganho que não sobrevive ao teste estatístico.**

A interpretação tem consequência prática. Com 10.000 imagens de treinamento, **não há sinal suficiente para reajustar proveitosamente 2,17 milhões de parâmetros convolucionais**: as características que a MobileNetV2 já extraiu da ImageNet servem ao CIFAR-10 como estão, e o descongelamento oferece à rede sobretudo capacidade de memorizar o conjunto de treinamento. Os registros de treinamento corroboram: na fase 2, a acurácia de treinamento atinge 99,8% enquanto a de validação permanece estacionária em torno de 85% — a definição operacional de sobreajuste.

Cabe destacar que o notebook da disciplina **congela o backbone e nunca o descongela** — procedimento que, conforme a seção de desvios metodológicos, é extração de características com cabeça densa, e não ajuste fino. Este experimento indica que, **neste regime de dados, tal procedimento não acarreta perda de desempenho**. O desvio metodológico aqui implementado — a fase 2 de descongelamento — foi executado, mensurado, e não produziu ganho estatisticamente detectável.

Acurácia por minuto de GPU

Estratégia	Acurácia	Treino	pp acima da CNN do zero	pp por minuto
5 — Ajuste fino de ViT	0,9825	6,7 min	+21,89 pp	+3,25
4 — Ajuste fino + aumento de dados	0,8650	8,6 min	+10,14 pp	+1,18
3 — Ajuste fino	0,8576	3,3 min	+9,40 pp	+2,86
2 — Extração de características	0,8522	0,6 min	+8,86 pp	+14,45
1 — CNN do zero	0,7636	1,7 min	+0,00 pp	+0,00


A pergunta do enunciado — qual estratégia é a melhor — não admite resposta sem um eixo de custo. Uma vantagem de 0,1 ponto percentual obtida ao preço de vinte vezes mais computação não constitui superioridade sob qualquer critério de engenharia aplicável.

A extração de características é, por larga margem, a estratégia mais eficiente: entrega **14,45 pontos percentuais por minuto** de GPU acima da CNN treinada do zero, contra 3,25 do ViT, 2,86 do ajuste fino e 1,18 do ajuste fino com aumento de dados. Uma ordem de grandeza separa a primeira colocada da segunda nesse critério.

Isso **não contradiz** a tabela de acurácia — o ViT permanece o modelo mais acurado, e por larga margem. O que o eixo de custo estabelece é que as duas perguntas têm **respostas diferentes**: se o critério é acurácia máxima, a resposta é o ViT; se é acurácia por unidade de recurso, a resposta é a extração de características. Um relatório que reportasse apenas a primeira coluna omitiria do leitor o fato de que **81% do ganho de transferência sobre a CNN do zero (8,86 dos 10,94 pp atingidos pela melhor estratégia convolucional) é capturado em 36 segundos de GPU**, sem treinar um único parâmetro convolucional.

O aumento de dados, por sua vez, justifica seu custo. A Estratégia 4 supera a Estratégia 3 em **+0,92 pp** com significância ($p = 4,0 \times 10^{-4}$) — é o único incremento sobre o ajuste fino que sobrevive ao teste. Resultado coerente com o regime de poucos dados: se 10.000 imagens são insuficientes para reajustar o backbone, ampliá-las artificialmente ataca precisamente a restrição vigente.

Matriz de confusão do melhor modelo



Matriz normalizada por linha: cada célula lê-se como “desta classe verdadeira, tal fração foi predita como aquela classe”. Valores em porcentagem.

Principais confusões

Confusão	Taxa	Leitura
dog → cat	3,6%	
cat → dog	2,3%	
truck → automobile	1,5%	
automobile → truck	1,0%	
bird → cat	0,7%	

O erro residual do ViT é semanticamente estruturado, e não disperso. As cinco maiores confusões concentram-se em dois pares: dog ↔ cat (3,6% e 2,3%) e truck ↔ automobile (1,5% e 1,0%). São

os dois pares de classes semanticamente adjacentes do CIFAR-10 — animais domésticos quadrúpedes de porte comparável, e veículos terrestres de quatro rodas.

A estrutura do erro é, portanto, **compatível com a hipótese** de que o que resta a discriminar depende de detalhes de textura e proporção pouco preservados a 32×32 pixels. Cabe, porém, distinguir o que a evidência sustenta do que ela não sustenta: **a matriz de confusão exibe um padrão, e não demonstra um limite intrínseco da base**. Estabelecer que esses erros são irreduzíveis exigiria evidência que este experimento não produz — por exemplo, a taxa de concordância entre anotadores humanos sobre as imagens confundidas, ou o desempenho de um modelo de capacidade muito superior sobre o mesmo par de classes. A afirmação defensável é mais modesta: **o erro remanescente não é aleatório, e concentra-se onde a semelhança semântica é maior**.

Investigações Complementares

O enunciado formula quatro questões de investigação. **Todas foram conduzidas e respondidas**. As conclusões sintéticas são apresentadas a seguir; cada seção subsequente detalha o delineamento, os resultados e os testes de significância.

Questão	Evidência	Conclusão
2(a) Trocar a CNN por uma mais simples (MobileNet) impacta significativamente o resultado?	6 configurações (3 backbones × 2 classificadores), 1 <i>seed</i>	Sim . A adoção da MobileNetV2 custa 2,39 pp de acurácia frente à ResNet50 ($p = 4 \times 10^{-10}$). A InceptionV3, contudo, a mais custosa das três, é a de pior desempenho: capacidade não prediz qualidade de transferência .
4(a) Substituir <code>Flatten()</code> por <code>GlobalMaxPooling2D()</code> impacta significativamente o resultado?	3 configurações, 2 <i>seeds</i> por braço	Sim, e favoravelmente : +1,19 pp ($p = 9 \times 10^{-5}$). O melhor braço, porém, é o <code>GlobalAveragePooling2D()</code> , em empate técnico com o máximo — o mérito é do agrupamento global como classe de operação.
4(b) Substituir o otimizador (<code>Adam()</code>) pode melhorar o resultado?	4 otimizadores × 2 <i>seeds</i>	Não . Nenhum supera o Adam significativamente (AdamW: +0,08 pp; $p = 0,087$). O achado está na dispersão: o SGD varia 5,4 pp entre <i>seeds</i> — 29× o desvio do AdamW.
4(c) Outras estratégias de aumento de dados podem melhorar o resultado?	4 políticas × 2 <i>seeds</i>	Sim, mas não como previsto . A política da disciplina empata com a melhor; o espelhamento horizontal isolado é a pior . A hipótese registrada por este relatório foi refutada .

Nenhum valor é estimado, inferido ou reportado sem o artefato correspondente em [results/](#). A ausência de uma tabela indica que o experimento não foi conduzido — e não que seu resultado tenha sido desfavorável.

2(a) — Trocar a rede CNN por uma mais simples, como a MobileNet, impacta significativamente o resultado?

Investigação conduzida. Seis configurações, uma seed.

Backbone + classificador	Acurácia (média ± dp, 1 seeds)	Δ vs. melhor	Macro-F1	Treino
resnet50_svm	0,8761	+0,00 pp	0,8767	1,0 min
resnet50_mlp	0,8651	-1,10 pp	0,8653	0,4 min
mobilenetv2_svm	0,8522	-2,39 pp	0,8524	0,6 min
mobilenetv2_mlp	0,8392	-3,69 pp	0,8389	0,7 min
inceptionv3_svm	0,7867	-8,94 pp	0,7867	1,6 min
inceptionv3_mlp	0,7796	-9,65 pp	0,7793	0,6 min

Ablação controlada: o classificador raso, os dados e o protocolo permanecem fixos; varia-se exclusivamente a rede extratora.

Resposta: sim, a troca impacta significativamente — mas não na direção que a intuição sugere. A ResNet50 (0,8761) supera a MobileNetV2 (0,8522) em **+2,39 pontos percentuais**, e o teste exato de McNemar confirma a diferença ($p = 4,1 \times 10^{-10}$). Adotar a rede mais simples, portanto, **custa** acurácia — o que responde afirmativamente à questão do enunciado.

Contudo, o resultado mais informativo é a InceptionV3. Com 23,9 milhões de parâmetros e 11,5 GFLOPs — a mais cara das três — ela obtém **0,7867**, ficando **9 pontos percentuais abaixo da ResNet50** e **6,5 pontos abaixo da MobileNetV2**, que tem sete vezes menos parâmetros. **Capacidade não prediz qualidade de transferência.** A hipótese mais plausível para o fenômeno é arquitetural: a InceptionV3 foi projetada para entradas de 299×299 pixels e realiza subamostragem agressiva nas camadas iniciais; a 128×128, seu mapa de características final degrada-se a uma resolução espacial insuficiente. Registre-se que isso constitui uma **limitação da ablação**, e não uma propriedade intrínseca da rede: as três operam a 128 px por exigência do orçamento computacional, e essa resolução é nativa para a MobileNetV2, tolerável para a ResNet50 e adversa para a InceptionV3. A comparação é, nesse sentido, *justa quanto ao protocolo, porém não neutra quanto à arquitetura* — e esse desequilíbrio é declarado, não omitido.

Limitação desta ablação: uma única seed. As seis configurações foram executadas apenas na seed 42. O teste de McNemar sustenta que, **para aquelas predições**, a ResNet50 supera a MobileNetV2 de modo não atribuível ao acaso amostral do conjunto de teste — mas ele **não mede a estabilidade da conclusão frente à aleatoriedade do treinamento**. A estimativa de ruído de treinamento apresentada no protocolo (0,46 pp entre execuções idênticas) situa a margem aqui observada (2,39 pp) em cerca de cinco vezes essa variação, o que torna improvável — porém **não medida** — a inversão do ordenamento. A ordenação entre ResNet50 e MobileNetV2 é reportada como **provável**, não como estabelecida.

A SVM supera o MLP em todos os três backbones (+2,4 pp, +1,3 pp e +0,7 pp), sem exceção. Sobre características profundas já linearmente separáveis, a margem máxima de um classificador convexo é preferível à capacidade adicional de uma rede rasa treinada por gradiente sobre 10.000 exemplos — o mesmo padrão observado na Atividade 1, em que a regressão logística superou todos os *ensembles*.

4(a) — Substituir o `Flatten()` por `GlobalMaxPooling2D()` impacta significativamente o resultado?

Investigação conduzida. Três configurações, duas seeds.

Cabeça (pooling)	Acurácia (média ± dp, 2 seeds)	Δ vs. melhor	Macro-F1	Treino
mobilenetv2_gap	0,8576 ± 0,0025	+0,00 pp	0,8575	3,3 min
mobilenetv2_gmp	0,8558 ± 0,0020	-0,18 pp	0,8555	3,5 min
mobilenetv2_flatten	0,8470 ± 0,0063	-1,06 pp	0,8465	4,0 min

Resposta: sim — o `GlobalMaxPooling2D()` melhora sobre o `Flatten()`, em +1,19 pontos percentuais, com significância (0,8558 contra 0,8470; $p = 9,4 \times 10^{-5}$).

Duas precisões são necessárias, contudo, para não superinterpretar o resultado. Primeira: **o melhor desempenho observado não é do `GlobalMaxPooling2D()`, e sim do `GlobalAveragePooling2D()`** (0,8576), incluído como terceiro braço da ablação. Segunda: os dois **empatam tecnicamente** entre si ($\Delta = +0,14$ pp; $p = 0,598$), de modo que o experimento **não autoriza preferir um ao outro**.

A conclusão que a evidência sustenta é, portanto: **qualquer agrupamento global supera o achatamento; entre média e máximo, este protocolo não detecta diferença**. A substituição sugerida pelo enunciado é benéfica, mas o mérito pertence ao *agrupamento global* enquanto classe de operação — não à escolha do máximo em particular.

O mecanismo é o número de parâmetros. Sobre a MobileNetV2 em 128 px, o mapa de características final tem dimensão 4×4×1280; logo:

Cabeça	Parâmetros treináveis	Acurácia (2 seeds)
Flatten() → Dense(512)	12.002.122	0,8470 ± 0,0063
GlobalMaxPooling2D() → Dense(512)	2.171.722	0,8558 ± 0,0020
GlobalAveragePooling2D() → Dense(512)	2.171.722	0,8576 ± 0,0025

O `Flatten()` exige **5,5 vezes mais parâmetros** para entregar acurácia **inferior** — e com **dispersão 2,5 vezes maior** entre *seeds* ($\pm 0,0063$ contra $\pm 0,0025$), sinal de instabilidade. O `Flatten()` preserva a posição espacial de cada ativação; contudo, na classificação de objetos, a posição constitui majoritariamente **variável de perturbação** — a identidade da classe independe da localização do objeto no enquadramento. Exigir que a rede induza tal invariância a partir de 10.000 exemplos consome capacidade que o agrupamento global fornece por construção arquitetural.

Cabe registrar que **o notebook da disciplina utiliza `Flatten()`** — e que a alternativa comentada no próprio código (`#model.add(GlobalMaxPooling2D())`) é, conforme esta ablação demonstra, a melhor escolha.

4(b) — Substituir o algoritmo otimizador (`Adam()`) pode melhorar o resultado?

Investigação conduzida. Quatro otimizadores, duas seeds por braço.

Otimizador	Acurácia (média ± dp, 2 seeds)	Δ vs. melhor	Macro-F1	Treino
adamw	0,8660 ± 0,0013	+0,00 pp	0,8659	12,7 min
adam	0,8652 ± 0,0034	-0,09 pp	0,8648	13,4 min
rmsprop	0,8638 ± 0,0027	-0,22 pp	0,8637	12,7 min
sgd	0,8349 ± 0,0380	-3,12 pp	0,8351	11,1 min

Resposta: não. Nenhum otimizador supera o Adam de modo estatisticamente significativo. O AdamW obtém a maior média (0,8660 contra 0,8652 do Adam), mas a diferença de **0,08 ponto percentual** é inferior a um quinto do ruído de treinamento medido (0,46 pp), e o teste exato de McNemar não a distingue de zero ($p = 0,087$). O RMSprop fica 0,14 pp abaixo do Adam. **A configuração padrão do enunciado já é adequada**, e a substituição do otimizador não constitui via de melhoria neste delineamento.

O resultado informativo desta ablação não está nas médias, e sim na dispersão.

Otimizador	Média (2 seeds)	Desvio-padrão	Razão vs. AdamW
AdamW	0,8660	$\pm 0,0013$	1×
Adam	0,8652	$\pm 0,0034$	2,6×
RMSprop	0,8638	$\pm 0,0027$	2,1×
SGD + Nesterov	0,8349	$\pm 0,0380$	29×

O SGD produziu **0,8617** em uma *seed* e **0,8080** na outra — **5,4 pontos percentuais de diferença entre execuções que variam apenas na inicialização dos pesos**. Sua dispersão é vinte e nove vezes a do AdamW. A resposta útil à questão não é, portanto, que o SGD seja pior *em média*, mas que ele é **inconfiável neste regime**: uma execução única do SGD tem probabilidade não desprezível de produzir um resultado catastróficamente inferior, e nenhum protocolo baseado em execução única seria capaz de detectá-lo.

Uma limitação do delineamento, exposta por esta ablação. A investigação da execução anômala (`sgd`, *seed* 7) revela que sua **melhor acurácia de validação ocorreu na fase 1** (época 10 de 27), isto é, **antes do descongelamento**. Todas as demais execuções desta ablação têm sua melhor época na fase 2 (Adam: 22 e 25; AdamW: 25 e 24; RMSprop: 21 e 24). Como a parada antecipada seleciona o melhor modelo **dentro de cada fase**, e não globalmente entre as duas, o protocolo reportou o modelo da fase 2 — inferior, neste caso, ao que a fase 1 havia produzido.

Trata-se de um pressuposto implícito do delineamento em duas fases: **o de que a fase 2 aprimora o resultado da fase 1**. O pressuposto é válido para os três otimizadores estáveis, e falha exatamente para o instável. A correção — seleção global de modelo entre as duas fases — é direta, e está registrada como trabalho futuro; sua ausência afeta apenas a execução anômala aqui identificada, e a afeta na direção conservadora (subestimando o SGD, não superestimando-o).

4(c) — Avaliar outras estratégias de aumento de dados pode melhorar o resultado?

Investigação conduzida. Quatro políticas, duas seeds por braço.

Política de aumento de dados	Acurácia (média $\pm$ dp, 2 seeds)	Δ vs. melhor	Macro-F1	Treino
<code>strong</code>	0,8678 $\pm$ 0,0010	+0,00 pp	0,8672	20,7 min
<code>lecture</code>	0,8676 $\pm$ 0,0014	-0,02 pp	0,8672	21,0 min
<code>flip_crop</code>	0,8653 $\pm$ 0,0004	-0,25 pp	0,8649	11,5 min
<code>flip</code>	0,8590 $\pm$ 0,0028	-0,88 pp	0,8585	6,3 min

Resposta: sim, a política importa — porém não na direção que este relatório havia previsto.

Política	Média (2 seeds)	Desvio-padrão	Treino
<code>strong</code> (flip + rotação + zoom + deslocamento + contraste)	0,8678	$\pm 0,0010$	20,7 min
<code>lecture</code> (a do notebook da disciplina)	0,8676	$\pm 0,0014$	21,0 min
<code>flip_crop</code> (espelhamento + deslocamento 12,5%)	0,8653	$\pm 0,0004$	11,5 min
<code>flip</code> (apenas espelhamento horizontal)	0,8590	$\pm 0,0028$	6,3 min

Os vereditos pareados (McNemar exato, *seed* 42) são: `lecture` supera `flip` em **+0,76 pp** com significância ($p = 0,0037$); `lecture` **empata tecnicamente** com `flip_crop` ($p = 0,159$) e com `strong` ($p = 0,547$).

A hipótese registrada por este relatório antes da execução foi refutada. Na seção de desvios metodológicos afirmou-se que a política da disciplina "*deixa desempenho na mesa*" por omitir o espelhamento horizontal — transformação reportada na literatura como das mais eficazes sobre o CIFAR-10. Os dados contradizem a expectativa em dois pontos:

1. **A política da disciplina figura entre as melhores**, em empate técnico com a política mais elaborada do delineamento (`strong`), que aplica cinco transformações — inclusive o espelhamento — e custa o mesmo tempo.
2. **O espelhamento horizontal isolado é a pior política testada**, significativamente inferior à da disciplina.

A explicação mais plausível reside na **diferença de regime**. A eficácia do espelhamento horizontal é estabelecida na literatura para redes convolucionais **treinadas do zero**, sobre as 50.000 imagens completas, ao longo de centenas de épocas. O regime aqui é outro: **backbone pré-treinado na ImageNet**, 10.000 imagens, 27 épocas, maioria dos pesos congelada. Nesse contexto, o **backbone** já incorpora invariância a espelhamento — adquirida sobre milhões de imagens que contêm objetos em ambas as orientações —, e reensiná-la não acrescenta informação, apenas consome épocas. As transformações que a política da disciplina aplica (rotação, zoom, deslocamento) atacam variações **não** cobertas pelo pré-treinamento, e é isso que as torna produtivas.

A conclusão metodológica supera, em interesse, a conclusão empírica: uma heurística validada em um regime não transfere automaticamente para outro. É, aliás, a mesma lição que a Estratégia 3 já havia produzido — o ajuste fino, prática padrão em regimes de dados abundantes, não se justifica com 10.000 imagens. O valor de registrar a hipótese *antes* do experimento está precisamente aqui: uma previsão refutada pelos próprios dados é resultado; uma previsão jamais formulada não é coisa alguma.

Custo. Cabe registrar que `flip_crop` atinge 99,7% da acurácia da política vencedora consumindo **metade do tempo de treinamento** (11,5 contra 20,7 minutos), e empata tecnicamente com ela. Sob restrição computacional, é a escolha racional.

Scripts

Todo o código é versionado e executável de forma independente. O notebook Colab é apenas o ambiente de execução; o artefato científico são os scripts.

Componente	Script
Protocolo compartilhado (splits, avaliação, McNemar, IC de Wilson)	<code>common.py</code>
Estratégia 1 — CNN do zero	<code>s1_cnn_scratch.py</code>
Estratégia 2 — Extração de características	<code>s2_feature_extraction.py</code>
Estratégia 3 — Ajuste fino	<code>s3_finetuning.py</code>
Estratégia 4 — Ajuste fino + aumento de dados	<code>s4_augmentation.py</code>
Estratégia 5 — Ajuste fino de ViT	<code>s5_vit.py</code>
Orquestrador (todas as etapas e ablações)	<code>run_all.py</code>
Gerador do relatório (tabelas, matriz de confusão, testes)	<code>report.py</code>
Executor Colab (GPU)	<code>colab.ipynb</code>
Artefatos de resultado (JSON, com as predições de teste)	<code>results/</code>

Repositório: <https://github.com/fsd-dantas/machine-learning-fundamentals>

[← Relatório completo \(inglês\)](#) · [Módulo 5 — Técnicas Profundas](#)