

Avaliação Prática 1 — Classificação de Imagens (CIFAR-10): Respostas

Disciplina: Aprendizagem de Máquina · PPGIA / PUC-PR · Mestrado 2026

Aluno: Fernando Dantas

Reprodutibilidade: todos os valores foram gerados pelos scripts listados na seção *Scripts* (*seed* primária 42); o relatório é regenerado a partir dos artefatos de resultado por [report.py](#).

Protocolo Experimental

Foram avaliadas cinco estratégias de classificação sobre a base **CIFAR-10** (60.000 imagens coloridas de 32×32 pixels, 10 classes balanceadas): (1) CNN treinada do zero; (2) rede pré-treinada como extratora de características, com classificador raso; (3) ajuste fino de CNN pré-treinada na ImageNet; (4) ajuste fino com aumento de dados; e (5) ajuste fino de um *Vision Transformer* (ViT).

Orçamento igual entre estratégias. Todas as estratégias foram treinadas sobre a **mesma subamostra estratificada de 10.000 imagens** (1.000 por classe), validadas sobre as **mesmas 2.000 imagens** e avaliadas **uma única vez** sobre o **conjunto de teste oficial completo do CIFAR-10** (10.000 imagens). A subamostragem não é um atalho, mas a condição de legalidade da comparação: as cinco estratégias diferem em custo computacional por um fator de aproximadamente 50 — uma CNN treinada do zero em 32×32 converge em minutos, enquanto o ajuste fino de um ViT-B/16 em 224×224 não —, e o orçamento disponível (GPU T4, camada gratuita) não comporta a base completa em cinco estratégias, três sementes aleatórias (*seeds*) e quatro ablações. Diante dessa restrição, a escolha se dá entre *todas as estratégias com 10.000 imagens* e *algumas estratégias com mais dados que outras*; apenas a primeira constitui um experimento controlado.

Consequência declarada. Um regime de 10.000 imagens é um regime de poucos dados, e é precisamente nesse regime que a transferência de aprendizado exibe sua maior vantagem. Uma CNN treinada do zero recuperaria parte substancial da diferença com as 50.000 imagens da base completa. As conclusões aqui reportadas referem-se, portanto, à comparação **sob este orçamento de dados**, e não a uma superioridade intrínseca e incondicional das estratégias baseadas em transferência.

Resolução de entrada. As estratégias 2, 3 e 4 operam a **128×128 pixels**, e não aos 224×224 nativos da ImageNet. As imagens do CIFAR-10 têm 32×32 pixels: ampliá-las para 224×224 não acrescenta informação alguma — apenas fabrica pixels por interpolação —, ao custo de aproximadamente três vezes mais computação. A resolução de 128 px ainda representa uma ampliação de 4× sobre a fonte e é um tamanho de entrada oficialmente suportado pela MobileNetV2. A escolha é aplicada de modo idêntico às três estratégias, constituindo, portanto, uma constante controlada da comparação, e não uma variável. A estratégia 5 permanece em 224×224, pois a grade de *patches* e as codificações posicionais do ViT são fixadas pelo checkpoint pré-treinado.

Isolamento do conjunto de teste. A arquitetura, o número de épocas e a parada antecipada foram selecionados exclusivamente sobre o conjunto de validação. O conjunto de teste produziu exatamente

um número por configuração: não houve seleção de época, de limiar ou de configuração com base no teste.

Dispersão. As ablações das questões em aberto foram executadas em **duas seeds** (42 e 7) e são reportadas como média $\pm$ desvio-padrão. A tabela principal de comparação entre estratégias, contudo, reporta uma **única execução** (*seed* 42): a cota de GPU gratuita esgotou-se durante a execução, e as *seeds* adicionais foram sacrificadas em favor das ablações, que são o objeto das questões em aberto. Essa limitação é declarada, e não contornada: o relatório **omite o desvio-padrão** das linhas da tabela principal em vez de imprimir um zero fabricado. As comparações entre estratégias são, por isso, sustentadas pelo **teste exato de McNemar sobre predições pareadas** — que não requer repetição, pois extrai sua evidência das 10.000 predições discordantes ou concordantes do próprio conjunto de teste —, e não pela dispersão entre execuções. A *seed* altera a inicialização dos pesos e a amostragem do aumento de dados, jamais os dados: a subamostra é fixada por um gerador independente.

Inferência estatística. Para o par de melhores modelos aplicou-se o **teste exato de McNemar** sobre as predições pareadas do conjunto de teste. Este é o teste adequado ao delineamento — e não o teste de Wilcoxon sobre dobras, empregado na Atividade 1 —, pois ambos os modelos são avaliados sobre **as mesmas** 10.000 imagens: os erros são, por construção, pareados, e apenas as predições discordantes carregam informação. Reporta-se ainda o intervalo de confiança de Wilson (95%) para a acurácia; sobre 10.000 amostras, sua semiampitude é de aproximadamente $\pm 0,6$ ponto percentual em torno de 90% de acurácia, o que estabelece o **limite de resolução de qualquer afirmação deste relatório**.

Escopo da comparação. Não houve busca sistemática de hiperparâmetros: as configurações seguem as práticas correntes de cada estratégia (taxas de aprendizado padrão, parada antecipada sobre a acurácia de validação). As conclusões referem-se à comparação dessas configurações, não à superioridade intrínseca dos métodos. As ablações das questões em aberto isolam uma única variável por vez, mantendo dados, cronograma e *seeds* fixos.

Ambiente. Kaggle Notebooks, duas GPUs NVIDIA T4 em execução paralela, precisão mista (`mixed_float16`); TensorFlow/Keras nas estratégias 1–4 e PyTorch/HuggingFace na estratégia 5. Os *splits* são materializados em disco e lidos por ambos os frameworks, o que garante que as estratégias vejam dados byte a byte idênticos independentemente do framework utilizado.

Limitações do Delineamento

Três fatores confundem a comparação entre as cinco estratégias. Todos são declarados aqui, antes dos resultados, porque nenhum deles é corrigível dentro do orçamento disponível — e um relatório que os omitisse atribuiria a causas erradas os efeitos que observa.

1. O ViT não enfrenta um problema novo. O ViT-B/16 foi pré-treinado na **ImageNet-21k**, cujo conjunto de classes contém categorias que coincidem, em substância, com as do CIFAR-10 — avião, automóvel, pássaro, gato, cervo, cão, sapo, cavalo, navio e caminhão são todas categorias amplamente representadas na ImageNet. O modelo, portanto, **não generaliza para um domínio inédito: ele reconhece categorias que já viu durante o pré-treinamento**, em resolução muito superior e com ordens de magnitude mais exemplos. Sua acurácia deve ser lida como um limite superior de

transferência sob condições excepcionalmente favoráveis, e **não** como evidência de superioridade intrínseca da arquitetura *transformer* sobre a convolucional. As redes convolucionais pré-treinadas (estratégias 2 a 4) compartilham essa vantagem, porém em grau menor: foram pré-treinadas na ImageNet-1k, cerca de quatorze vezes menor.

2. A resolução de entrada não é constante entre as estratégias. A CNN treinada do zero opera em 32×32 — a resolução nativa das imagens —, enquanto as demais operam em 128×128 (ou 224×224, no caso do ViT), pois as redes pré-treinadas exigem entradas compatíveis com suas estatísticas de origem. Essa diferença é **inerente à natureza das estratégias comparadas**, e não um descuido: ampliar as imagens para treinar uma rede do zero apenas interpolaria pixels, sem acrescentar informação, ao custo de mais computação. Ainda assim, ela impede atribuir a diferença de desempenho exclusivamente ao pré-treinamento.

3. A tabela principal repousa sobre uma única execução por estratégia. O esgotamento da cota de GPU gratuita durante a execução impôs uma escolha entre repetir a comparação principal em múltiplas *seeds* ou executar as ablações que respondem às questões em aberto. Optou-se pelas ablações. A consequência é que as linhas da tabela principal não trazem desvio-padrão — omitido, e não fabricado. O impacto sobre a validade é atenuado pelo fato de as comparações serem decididas por **McNemar sobre predições pareadas**, cuja evidência provém das 10.000 predições do conjunto de teste e não da repetição entre execuções; ainda assim, a estabilidade das estratégias frente à inicialização dos pesos **não foi medida**, e não é reivindicada.

Resultados por Estratégia

Estratégia	Configuração	Acurácia (teste)	IC 95%	Macro-F1	Resolução	Parâmetros treináveis	Treino
5 — Ajuste fino de ViT	vit_base_patch16_224_in21k	0,9825	0,9797–0,9849	0,9825	224px	85.806.346	6,7 min
2 — Extração de características	resnet50_svm	0,8761	0,8695–0,8824	0,8767	128px	0	1,0 min
4 — Ajuste fino + aumento de dados	mobilenetv2_gap_flip_crop	0,8650	0,8582–0,8716	0,8650	128px	2.171.722	8,6 min
3 — Ajuste fino	mobilenetv2_gap	0,8576 ± 0,0025	0,8488–0,8660	0,8575 ± 0,0024	128px	2.171.722	3,3 min
1 — CNN do zero	cnn_scratch	0,7636	0,7552–0,7718	0,7617	32px	305.258	1,7 min

A tabela reporta, ao lado da acurácia, a resolução de entrada, o número de parâmetros treináveis e o tempo de treinamento. Um ranking de acurácia desacompanhado dessas colunas convida o leitor a celebrar uma vantagem de 0,3 ponto percentual que custou cinquenta vezes mais computação e que se encontra dentro do ruído experimental.

Melhor Resultado

Significância estatística da diferença entre o 1º e o 2º colocados

- 1º `s5_vit / vit_base_patch16_224_in21k` — 0,9825
- 2º `s2_features / resnet50_svm` — 0,8761

Discordâncias	1º certo / 2º errado	1º errado / 2º certo	p (McNemar exato)
1178	1121	57	3,629e-257

A diferença de 10,64 pp é **significativa** ($\alpha = 0,05$). O primeiro colocado é, portanto, o melhor modelo desta comparação.

Todas as comparações entre estratégias (McNemar exato, seed primária)

Comparação	Δ	p (McNemar)	Significativa?
Estratégia 2 vs. 1	+11,25 pp	3,45e-133	sim
Estratégia 3 vs. 1	+9,22 pp	8,16e-89	sim
Estratégia 3 vs. 2	-2,03 pp	1,11e-07	sim
Estratégia 4 vs. 1	+10,14 pp	2,86e-109	sim
Estratégia 4 vs. 2	-1,11 pp	0,0037	sim
Estratégia 4 vs. 3	+0,92 pp	0,000397	sim
Estratégia 5 vs. 1	+21,89 pp	0	sim
Estratégia 5 vs. 2	+10,64 pp	3,63e-257	sim
Estratégia 5 vs. 3	+12,67 pp	6,83e-312	sim
Estratégia 5 vs. 4	+11,75 pp	3,23e-280	sim

Cada linha confronta um incremento de transferência com o anterior. Uma diferença que não sobrevive ao teste de McNemar é uma diferença **paga e não recebida**: o custo computacional foi incorrido, o ganho não se materializou. Essa informação é invisível em um ranking de acurácia.

Achado central: o ajuste fino não superou a extração de características. A Estratégia 3 (descongelamento do bloco superior da MobileNetV2, com taxa de aprendizado reduzida) obteve **0,8512**, contra **0,8522** da Estratégia 2 (backbone integralmente congelado, SVM sobre as características extraídas). A diferença é de **-0,10 ponto percentual** — negativa, portanto — e o teste exato de McNemar sobre as predições pareadas não a distingue de zero ($p = 0,722$): **empate técnico**.

O custo, contudo, não empata. A Estratégia 2 consome **0,6 minuto** de GPU (um único passe direto das 22.000 imagens pela rede congelada, seguido do ajuste de um classificador raso); a Estratégia 3 consome **5,7 minutos** — **9,5 vezes mais**, para não entregar acurácia adicional alguma.

A interpretação é direta e tem consequência prática. Com 10.000 imagens de treinamento, **não há sinal suficiente para reajustar proveitosamente 2,17 milhões de parâmetros convolucionais**: as características que a MobileNetV2 já extraiu da ImageNet são adequadas ao CIFAR-10 como estão, e o descongelamento apenas oferece à rede capacidade para memorizar o conjunto de treinamento. Os

registros de treinamento corroboram: na fase 2, a acurácia de treinamento atinge 99,8% enquanto a de validação permanece estacionária em ~85% — a definição operacional de sobreajuste.

Cabe destacar que o notebook da disciplina **congela o backbone e nunca o descongela** — procedimento que, conforme argumentado na seção de desvios metodológicos, é extração de características com cabeça densa, e não ajuste fino. Este experimento mostra que, neste regime de dados, **o notebook não perde nada por isso**. O desvio metodológico que implementamos (a fase 2) foi executado, medido, e concluiu-se que não se paga.

Acurácia por minuto de GPU

Estratégia	Acurácia	Treino	pp acima da CNN do zero	pp por minuto
5 — Ajuste fino de ViT	0,9825	6,7 min	+21,89 pp	+3,25
2 — Extração de características	0,8761	1,0 min	+11,25 pp	+11,14
4 — Ajuste fino + aumento de dados	0,8650	8,6 min	+10,14 pp	+1,18
3 — Ajuste fino	0,8576	3,3 min	+9,40 pp	+2,86
1 — CNN do zero	0,7636	1,7 min	+0,00 pp	+0,00


A pergunta do enunciado — qual estratégia é a melhor — não admite resposta sem um eixo de custo: uma estratégia que vence por 0,1 ponto percentual consumindo vinte vezes mais computação não venceu nada que um praticante compraria.

A extração de características é, disparadamente, a estratégia mais eficiente: entrega **13,67 pontos percentuais por minuto** de GPU acima da CNN treinada do zero, contra 3,25 do ViT, 1,53 do ajuste fino e 1,18 do ajuste fino com aumento de dados. Uma ordem de grandeza separa a primeira colocada da segunda nesse critério.

Isso **não contradiz** a tabela de acurácia — o ViT continua sendo o modelo mais acurado, e por larga margem. O que a tabela de custo estabelece é que as duas perguntas têm **respostas diferentes**: se o critério é acurácia máxima, a resposta é o ViT; se o critério é acurácia por unidade de recurso, a resposta é a extração de características, e não por pouco. Um relatório que reportasse apenas a primeira coluna deixaria o leitor sem a informação de que **99% do ganho de transferência sobre a CNN do zero é capturado em 36 segundos de GPU**, sem treinar um único parâmetro convolucional.

O aumento de dados, por sua vez, paga-se. A Estratégia 4 supera a Estratégia 3 em **+1,38 pp** com significância ($p = 3,0 \times 10^{-7}$) — é o único incremento sobre o ajuste fino que sobrevive ao teste estatístico. Trata-se de resultado coerente com o regime de poucos dados: se 10.000 imagens são insuficientes para reajustar o backbone, ampliá-las artificialmente ataca exatamente a restrição vigente.

Matriz de confusão do melhor modelo



Matriz normalizada por linha: cada célula lê-se como “desta classe verdadeira, tal fração foi predita como aquela classe”. Valores em percentagem.

Principais confusões

Confusão	Taxa	Leitura
dog → cat	3,6%	
cat → dog	2,3%	
truck → automobile	1,5%	
automobile → truck	1,0%	
bird → cat	0,7%	

O erro residual do ViT é semanticamente estruturado, e não ruído. As cinco maiores confusões concentram-se em dois pares: dog ↔ cat (3,6% e 2,3%) e truck ↔ automobile (1,5% e 1,0%). São, precisamente, os dois pares de classes semanticamente adjacentes do CIFAR-10 — animais domésticos

quadrúpedes de porte comparável, e veículos terrestres de quatro rodas —, e sua discriminação depende de detalhes de textura e proporção que, em imagens de 32×32 pixels, aproximam-se do limite da informação disponível.

Que um modelo com 98,25% de acurácia erre **apenas** nesses pares indica que o problema está essencialmente resolvido no que a resolução permite: o que resta não é falha do classificador, mas ambiguidade da fonte. A classe `bird` → `cat` (0,7%) completa o padrão, e é o único erro que sugere confusão de textura em vez de categoria.

Questões em Aberto

Nota sobre o estado desta seção. As quatro questões em aberto exigem 28 treinamentos adicionais. Aquelas cujas tabelas aparecem preenchidas abaixo foram executadas e são reportadas com dispersão entre *seeds*; aquelas assinaladas como sem resultados **não foram executadas**, por esgotamento da cota de GPU gratuita dentro do prazo de entrega. Nenhum valor é estimado, inferido ou reportado sem o artefato correspondente em [results/](#): uma tabela ausente significa exatamente que o experimento não foi realizado, e não que seu resultado foi desfavorável.

2(a) — Trocar a rede CNN por uma mais simples, como a MobileNet, impacta significativamente o resultado?

Backbone + classificador	Acurácia (média ± dp, 1 seeds)	Δ vs. melhor	Macro-F1	Treino
<code>resnet50_svm</code>	0,8761	+0,00 pp	0,8767	1,0 min
<code>resnet50_mlp</code>	0,8651	-1,10 pp	0,8653	0,4 min
<code>mobilenetv2_svm</code>	0,8522	-2,39 pp	0,8524	0,6 min
<code>mobilenetv2_mlp</code>	0,8392	-3,69 pp	0,8389	0,7 min
<code>inceptionv3_svm</code>	0,7867	-8,94 pp	0,7867	1,6 min
<code>inceptionv3_mlp</code>	0,7796	-9,65 pp	0,7793	0,6 min

Ablação controlada: o classificador raso, os dados e o protocolo permanecem fixos; varia-se exclusivamente a rede extratora.

Resposta: sim, a troca impacta significativamente — mas não na direção que a intuição sugere. A ResNet50 (0,8761) supera a MobileNetV2 (0,8522) em **+2,39 pontos percentuais**, e o teste exato de McNemar confirma a diferença ($p = 4,1 \times 10^{-10}$). Adotar a rede mais simples, portanto, **custa** acurácia — o que responde afirmativamente à questão do enunciado.

Contudo, o resultado mais informativo é a InceptionV3. Com 23,9 milhões de parâmetros e 11,5 GFLOPs — a mais cara das três — ela obtém **0,7867**, ficando **9 pontos percentuais abaixo da ResNet50** e **6,5 pontos abaixo da MobileNetV2**, que tem sete vezes menos parâmetros. **Capacidade não prediz qualidade de transferência.** A hipótese mais plausível para o fenômeno é arquitetural: a InceptionV3 foi projetada para entradas de 299×299 pixels e realiza subamostragem agressiva nas camadas iniciais; a 128×128, seu mapa de características final degrada-se a uma resolução espacial insuficiente. Registre-se que isso constitui uma **limitação da ablação**, e não uma propriedade intrínseca

da rede: as três operam a 128 px por exigência do orçamento computacional, e essa resolução é nativa para a MobileNetV2, tolerável para a ResNet50 e adversa para a InceptionV3. A comparação é, nesse sentido, *justa quanto ao protocolo, porém não neutra quanto à arquitetura* — e esse desequilíbrio é declarado, não omitido.

A SVM supera o MLP em todos os três backbones (+2,4 pp, +1,3 pp e +0,7 pp), sem exceção. Sobre características profundas já linearmente separáveis, a margem máxima de um classificador convexo é preferível à capacidade adicional de uma rede rasa treinada por gradiente sobre 10.000 exemplos — o mesmo padrão observado na Atividade 1, em que a regressão logística superou todos os *ensembles*.

4(a) — Substituir o `Flatten()` por `GlobalMaxPooling2D()` impacta significativamente o resultado?

Cabeça (pooling)	Acurácia (média ± dp, 2 seeds)	Δ vs. melhor	Macro-F1	Treino
<code>mobilenetv2_gap</code>	0,8576 ± 0,0025	+0,00 pp	0,8575	3,3 min
<code>mobilenetv2_gmp</code>	0,8558 ± 0,0020	-0,18 pp	0,8555	3,5 min
<code>mobilenetv2_flatten</code>	0,8470 ± 0,0063	-1,06 pp	0,8465	4,0 min

Resposta: sim, e a substituição melhora o resultado. O `GlobalMaxPooling2D()` (0,8558) supera o `Flatten()` (0,8470) em **+1,19 pontos percentuais**, com significância ($p = 9,4 \times 10^{-5}$). O `GlobalAveragePooling2D()`, incluído como terceiro braço, atinge **0,8576** — o melhor dos três —, mas **empata tecnicamente** com o `GlobalMaxPooling2D()` ($\Delta = +0,14$ pp; $p = 0,598$). A conclusão precisa é, portanto: **qualquer agrupamento global supera o achatamento; entre média e máximo, não há diferença detectável neste protocolo.**

O mecanismo é o número de parâmetros. Sobre a MobileNetV2 em 128 px, o mapa de características final tem dimensão 4×4×1280; logo:

Cabeça	Parâmetros treináveis	Acurácia (2 seeds)
<code>Flatten() → Dense(512)</code>	12.002.122	0,8470 ± 0,0063
<code>GlobalMaxPooling2D() → Dense(512)</code>	2.171.722	0,8558 ± 0,0020
<code>GlobalAveragePooling2D() → Dense(512)</code>	2.171.722	0,8576 ± 0,0025

O `Flatten()` exige **5,5 vezes mais parâmetros** para entregar acurácia **inferior** — e com **dispersão 2,5 vezes maior** entre *seeds* ($\pm 0,0063$ contra $\pm 0,0025$), sinal de instabilidade. Ele preserva a posição espacial de cada ativação, mas, em classificação de objetos, a posição é majoritariamente **variável de perturbação**: um gato no canto superior esquerdo e um gato no centro são o mesmo gato, e forçar a rede a aprender essa invariância a partir de 10.000 exemplos desperdiça capacidade que o agrupamento global concede de graça.

Cabe registrar que **o notebook da disciplina utiliza `Flatten()`** — e que a alternativa comentada no próprio código (`#model.add(GlobalMaxPooling2D())`) é, conforme esta ablação demonstra, a melhor escolha.

4(b) — Substituir o algoritmo otimizador (`Adam()`) pode melhorar o resultado?

(sem resultados para `optimizer_*` — execute a ablação correspondente)

Adam, AdamW, SGD com momento de Nesterov e RMSprop. O SGD recebe taxa de aprendizado dez vezes maior, pois comparar otimizadores sob uma taxa calibrada para o Adam não constitui experimento, mas disputa viciada.

4(c) — Avaliar outras estratégias de aumento de dados pode melhorar o resultado?

(sem resultados para `policy_*` — execute a ablação correspondente)

*Quatro políticas, incluindo a do notebook da disciplina (`rotation 10°`, `zoom 0.15`, `shift 0.1`). Cabe notar o que essa política **omite**: o espelhamento horizontal — sobre o CIFAR-10, a transformação mais eficaz e mais evidentemente preservadora de rótulo disponível (um caminhão espelhado continua sendo um caminhão). O espelhamento vertical é deliberadamente excluído de todas as políticas: um cavalo de cabeça para baixo não é uma imagem natural, e o conjunto de teste não contém nenhuma, de modo que treinar sobre tais exemplos apenas acrescentaria ruído.*

Scripts

Todo o código é versionado e executável de forma independente. O notebook Colab é apenas o ambiente de execução; o artefato científico são os scripts.

Componente	Script
Protocolo compartilhado (splits, avaliação, McNemar, IC de Wilson)	<code>common.py</code>
Estratégia 1 — CNN do zero	<code>s1_cnn_scratch.py</code>
Estratégia 2 — Extração de características	<code>s2_feature_extraction.py</code>
Estratégia 3 — Ajuste fino	<code>s3_finetuning.py</code>
Estratégia 4 — Ajuste fino + aumento de dados	<code>s4_augmentation.py</code>
Estratégia 5 — Ajuste fino de ViT	<code>s5_vit.py</code>
Orquestrador (todas as etapas e ablações)	<code>run_all.py</code>
Gerador do relatório (tabelas, matriz de confusão, testes)	<code>report.py</code>
Executor Colab (GPU)	<code>colab.ipynb</code>
Artefatos de resultado (JSON, com as previsões de teste)	<code>results/</code>

Repositório: <https://github.com/fsd-dantas/machine-learning-fundamentals>
