

AVALIAÇÃO TEÓRICA

Aluno: **Fernando Sabino Dantas**

Questão 1

Na aprendizagem de máquina há métodos que devem ser utilizados no momento de avaliar as hipóteses de solução geradas para um determinado problema. No caso da aprendizagem supervisionada, o objetivo dos métodos de avaliação é quantificar a capacidade de generalização de modelos de classificação e regressão, ou seja, medir a capacidade de predição para exemplos não utilizados durante o treinamento.

ENUNCIADO

Considerando a avaliação de modelos preditivos, pretende-se estimar o desempenho futuro de um sistema projetado para a tarefa de classificação aplicado a um problema com número limitado de instâncias (exemplos). Assinale a alternativa que apresenta o método mais adequado para a avaliação de desempenho do modelo neste caso. Este considera a separação aleatória das instâncias disponíveis em N pastas ou *folds*. Treina-se com N-1 pastas, testa-se com uma delas. Repete-se o procedimento por N vezes, trocando a base de teste.

ALTERNATIVAS

A	Holdout.
B	Validação Cruzada (k-fold cross validation), que lida bem poucos dados ("número limitado de instâncias"), dividindo aleatoriamente a base em N partições (<i>folds</i>), conforme <i>modus operandus</i> do algoritmo.
C	Resubstituição.
D	Leave-one-subject-out.
E	Leave-one-out

Questão 2

A abordagem de aprendizado supervisionado baseada em instâncias tem como principal técnica o KNN (*K-Nearest Neighbors*). Esta técnica utiliza os K vizinhos mais próximos do exemplo de teste na base de treinamento para predição do valor do atributo alvo. Para tal, podemos considerar diferentes estratégias no momento de chegar a uma decisão com base nos rótulos dos vizinhos do teste.

ENUNCIADO PARA AFIRMATIVAS (comando)

Suponha que um classificador KNN (K=5) ao encontrar os 5 vizinhos mais próximos do exemplo de teste x_t na base de treinamento de um problema contendo 3 classes (A, B e C), observa que as três classes estão presentes na vizinhança. Analise as afirmações abaixo relacionadas às estratégias que podem ser utilizadas por este classificador para atribuir uma classe a x_t .

AFIRMATIVAS	
I. Uso de um esquema baseado em voto, sendo a classe que mais aparece na vizinhança (a mais votada) atribuída ao teste. Correto: regra de decisão do KNN II. Uso de um esquema para ponderar o voto de cada vizinho usando o inverso de sua distância com relação ao teste. Correto: distance-weighted KNN III. Uso de um esquema de desempate (se for o caso), escolhendo aleatoriamente uma dentre as classes mais votadas. Correto: com K=5 e 3 classes, empates são possíveis (e.g.: 2-2-1) IV. Uso de uma estrutura de dados auxiliar para organizar a base de treinamento e reduzir o tempo de classificação. É verdade que estruturas como kd-tree ou ball-tree aceleraram a busca dos K vizinhos mais próximos. Porém, isso é uma otimização de busca/desempenho computacional, não uma estratégia de decisão a partir dos rótulos dos vizinhos. V. Uso de um esquema para fornecer uma taxa de confiança à decisão do classificador com base na proporção de votos que a classe atribuída ao teste recebeu na vizinhança. Uma prática comum é usar a proporção de vizinhos que concordaram com a classe vencedora (ex.: 3 de 5 votos = 60% de confiança) como uma estimativa de confiança/probabilidade da predição. Isso é diretamente derivado dos rótulos da vizinhança, se enquadrando no escopo do comando.	
ENUNCIADO PARA ALTERNATIVAS	
É correto o que se afirma apenas em:	
ALTERNATIVAS	
A	I, II, III e V.
B	I, II, III e IV.
C	II e III.
D	III, IV e V.
E	I, II, III, IV e V.

Questão 3
Árvores de decisão são utilizadas para gerar classificadores. O algoritmo ID3 é um dos mais conhecidos algoritmos de geração de árvores de decisão, o qual leva em conta a importância dos atributos do problema no momento de criação da árvore. A importância dos atributos pode ser estimada com base no ganho de informação proporcionado pelo atributo, o qual é calculado a partir do conceito de entropia.
ENUNCIADO



Dada a árvore acima gerada para um problema cujo objetivo é prever se um indivíduo vai ou não jogar futebol, analise as afirmativas abaixo:

AFIRMATIVAS (OBRIGATÓRIO 5 ALTERNATIVAS)

- I. Os atributos Umidade e Vento apresentam os maiores ganhos de informação. **Falsa.** O atributo escolhido para a **raiz** da árvore é sempre aquele com o **maior ganho de informação sobre todo o conjunto de treinamento** — nesse caso, **Céu**. Umidade e Vento só entram em jogo nos nós filhos, calculados sobre **subconjuntos** dos dados (o subconjunto onde Céu=ensolarado, e o subconjunto onde Céu=chuvoso, respectivamente). Ou seja, Umidade e Vento têm o maior ganho *dentro do seu subconjunto local*, mas não superam Céu quando se considera a base completa — é justamente por isso que Céu está na raiz e eles não. A afirmativa induz a uma comparação incorreta.
- II. A árvore representa um problema de classificação com 5 classes. **Falsa.** Só existem dois valores possíveis: "joga futebol" e "não joga futebol". É um problema **binário** (2 classes), não 5.
- III. O exemplo de teste [Céu=chuvoso, Vento=não, umidade=alta] é classificado como "joga futebol" pela árvore de decisão. **Verdadeira.** Percorrendo a árvore: Céu=chuvoso → nó Vento → vento=não → "joga futebol". O valor de umidade nem é consultado nesse ramo, mas isso não invalida a classificação — a árvore simplesmente não precisa dele nesse caminho.
- IV. O exemplo de teste [Céu=nublado, vento=sim, umidade=alta] é classificado como "joga futebol" pela árvore de decisão. **Verdadeira.** Céu=nublado leva **diretamente** à "joga futebol", sem necessidade de consultar Vento ou Umidade. A árvore captura que, historicamente, sempre que estava nublado, jogava-se futebol independentemente dos demais atributos.
- V. Com base na árvore podemos afirmar que este é um problema de classificação originalmente definido com apenas 3 atributos de entrada. **Falsa.** A árvore **final** usa apenas os atributos que efetivamente contribuíram com ganho de informação suficiente para alguma divisão (Céu, Umidade, Vento). Isso **não implica** que o problema original só tinha esses 3 atributos — pode perfeitamente existir um 4º atributo no *dataset* original (classicamente, "Temperatura", no exemplo original de Mitchell) que **não aparece na árvore** simplesmente porque o algoritmo ID3 nunca o selecionou (seu ganho de informação nunca foi o máximo em nenhum nó). Árvores de decisão são seletivas por natureza — a ausência de um atributo na árvore não prova sua ausência no problema original.

É correto o que se afirma apenas em:

ALTERNATIVAS

A

I, II, III, IV e V.

B	III e V.
C	I, II, III e V.
D	III e IV.
E	III, IV e V.

QUESTÃO 4

Para avaliação de um classificador temos diferentes medidas de desempenho que devem ser utilizadas conforme características do problema a ser resolvido. Por exemplo, sabe-se que acurácia (ou taxa de acerto) não é adequada quando o problema apresenta desbalanceamento em termos de quantidade de exemplares por classe. Para bases desbalanceadas devemos utilizar F-Measure, Precisão e Revocação.

ENUNCIADO

Com relação às métricas utilizadas na avaliação de um classificador relacione a primeira coluna com a segunda.

- (A) Na diagonal temos os acertos do classificador, enquanto nas demais posição os erros cometidos.
 (B) Um modelo com FN=0 (sem falsos negativos) em 1 (valor máximo) neste métrica
 (C) Um modelo com FP=0 (sem falsos positivos), resulta em 1 (valor máximo) neste métrica
 (D) Representa a média harmônica entre precisão e revocação.
 (E) Representa a taxa de acerto global do classificador.

- (**E**) Acurácia
 (**D**) F-Measure (f1-score)
 (**B**) Revocação
 (**C**) Precisão
 (**A**) Matriz de Confusão

Assinale a alternativa que contém a associação correta das colunas:

ALTERNATIVAS

A	E, D, C, B, A.
B	E, D, B, C, A.
C	E, C, D, B, A.
D	D, E, C, B, A.
E	E, A, C, D, B.

Questão 5

Na aprendizagem não supervisionada a principal tarefa é o agrupamento. O objetivo desta tarefa é encontrar grupos (clusters) de instâncias que sejam similares segundo algum critério. Busca-se uma baixa dispersão dentro de cada cluster e alta dispersão entre clusters. Uma métrica muito utilizada na avaliação de agrupamentos é o índice silhueta.

ENUNCIADO

Após executar o algoritmo de agrupamento K-médias para um problema considerando a quantidade de grupos $k=2, 3, 4, 5$ e 6 foram observados os seguintes valores médios para o índice silhueta: $0.73, 0.75, 0.87, 0.63$ e 0.60 , respectivamente. Assinale a alternativa que corresponde ao melhor valor de k com base nestes resultados.

Considerando o índice da silhueta:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

onde:

- $a(i)$ = distância média da instância aos demais pontos do **mesmo** cluster (coesão interna)
- $b(i)$ = distância média da instância ao cluster vizinho mais próximo (separação entre clusters)

Interpretação:

- Valores **próximos de +1** → cluster bem definido, com baixa dispersão interna e alta separação em relação aos demais (exatamente o critério mencionado no enunciado da questão).
- Valores próximos de 0 → clusters sobrepostos/ambíguos.
- Valores negativos → instâncias possivelmente atribuídas ao cluster errado.

A média das silhuetas individuais é usada como **métrica global de qualidade do agrupamento** para um dado k , e a prática padrão é escolher o k que **maximiza** essa média (método conhecido como *Silhouette Analysis*, alternativa ao "método do cotovelo").

ALTERNATIVAS

A	2. 0,73
B	3. 0,75
C	4. 0,87 (maior valor)
D	5. 0,63
E	6. 0,60

Questão 6

Há aplicações da aprendizagem de máquina que demandam uma explicação para a predição fornecida pelo

modelo. Alguns modelos de aprendizagem de máquina são ditos caixa-preta por não fornecerem explicação para a decisão fornecida. Para algumas áreas de atividade humana isto pode ser inaceitável.

ENUNCIADO

Considere que você precisa desenvolver um sistema para a área de Medicina. Este sistema consiste em identificar em imagens histopatológicas a presença de tumor. Logo, a tarefa consiste em classificar tecidos (porções da imagem) como tumor ou não. Após avaliar diferentes indutores, você observou pequena diferença em termos de precisão (algo em torno de 1%). Contudo, na Medicina os especialistas precisam saber qual o raciocínio utilizado pelo modelo para chegar ao resultado. Tendo isto em mente, assinale a alternativa que apresenta o indutor atende facilmente a este requisito.

ALTERNATIVAS

A	SVM. Com kernels não-lineares (RBF, polinomial), o algoritmo opera em um espaço de características transformado e a decisão final é uma combinação ponderada de vetores de suporte — não há um "porquê" interpretável diretamente por um humano. Clássico modelo caixa-preta .
B	MLP. Redes neurais multicamadas distribuem o conhecimento em pesos sinápticos e ativações não-lineares entre múltiplas camadas ocultas. Não existe regra explícita e legível que explique a decisão — é o exemplo mais citado de modelo caixa-preta .
C	Árvore de Decisão. Este é o exemplo canônico de modelo caixa-branca (interpretável). A predição corresponde a um caminho específico de testes sequenciais sobre atributos (ex.: "se textura > X E intensidade < Y → tumor"), que pode ser lido e traduzido diretamente em uma regra lógica <i>if-then</i> . É exatamente esse tipo de rastreabilidade que áreas regulamentadas como Medicina e Direito costumam exigir.
D	KNN. Parcialmente interpretável, mas não idealmente: pode-se dizer "este caso foi classificado como tumor porque é parecido com estes K casos históricos", mas isso não constitui uma explicação de raciocínio no sentido de regras de decisão — apenas indica similaridade com exemplos passados, sem revelar quais características levaram à decisão de forma estruturada.
E	Naive Bayes. Fornece probabilidades por classe baseados em produtos de probabilidades condicionais, mas a explicação depende de entender o modelo probabilístico subjacente (e a suposição de independência entre atributos), o que é menos direto e didático que uma sequência de regras <i>if-then</i> de uma árvore.

Questão 7

O “**Teorema de Bayes**”, criado por **Thomas Bayes** (1701-1761) para tentar provar a existência de Deus, é muito utilizado atualmente na Aprendizagem de Máquina Supervisionada. Dentre as técnicas derivadas deste importante teorema da Probabilidade e Estatística, destaca-se o algoritmo Naive Bayes que é utilizado em tarefas de classificação.

ENUNCIADO	
Considerando o algoritmo Naive Bayes, analise as afirmativas abaixo:	
AFIRMATIVAS	
I. Utilizado para aproximar funções alvo de valor discreto. Correto II. Considera independência entre os atributos de entrada do problema. Correto III. Facilita a aplicação do Teorema de Bayes na aprendizagem de máquina. Correto IV. Recebe o nome de "Naive" (ingênuo, simples) por desconsiderar possível correlação entre os atributos de entrada do problema. Correto V. Possui alto custo computacional na fase operacional, ou fase de testes. Falsa. Naive Bayes é conhecido justamente pelo baixo custo computacional, tanto no treinamento quanto na fase de testes/operação. Na fase de predição, basta multiplicar as probabilidades condicionais já estimadas (uma operação linear no número de atributos), sem otimização iterativa ou cálculos complexos como em SVM ou redes neurais. É um dos classificadores mais rápidos e escaláveis que existem, sendo inclusive usado como baseline em problemas de alta dimensionalidade (ex.: classificação de texto).	
É correto o que se afirma apenas em:	
ALTERNATIVAS	
A	I e II.
B	II, III e IV.
C	II e V.
D	I, III e IV.
E	I, II, III e IV.

Questão 8
Cada neurônio de uma rede neural artificial do tipo MLP (<i>MultiLayer Perceptron</i>) possui uma função de ativação que recebe um valor de entrada (somatório das entradas ponderadas do neurônio) e emite um valor de saída. Com a evolução das redes neurais foram surgindo diversas funções de ativação, cada uma com uma formulação matemática própria.
ENUNCIADO
Considerando a construção de um classificador MLP, assinale a alternativa que apresenta função de ativação que pode ser utilizada nos neurônios de saída para transformar o <i>score</i> de cada classe em um valor entre 0 e 1, normalizado, de tal forma que a soma destes <i>scores</i> resulta em 1.
ALTERNATIVAS

A	Softmax. A função Softmax transforma um vetor de <i>scores</i> brutos (<i>logits</i>) de saída, um para cada classe, em uma distribuição de probabilidade: $\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$
B	Tangh. (-1, 1)
C	Threshold. {0, 1} (binário)
D	RELU. [0, +∞) sem limite superior e não é normalizado
E	Sigmóide. Não necessariamente, porque comprime cada saída individualmente entre 0 e 1, mas cada neurônio de saída é calculado independentemente, ou seja, não há normalização conjunta que force a soma a ser 1. É adequada para classificação binária ou multi-rótulo (<i>labels</i> independentes), mas não garante a propriedade de "soma = 1" exigida no enunciado, que é exclusiva da Softmax (por seu denominador normalizador compartilhado entre todas as saídas).

Questão 9										
A máquina de vetor de suporte (SVM, Support Vector Machine) é originalmente um classificador binário. Contudo, podemos utilizá-lo para problemas de múltiplas classes usando as estratégias um-contra-todos ou todos-contra-todos. A quantidade de classificadores a serem gerados pode variar de acordo com a estratégia utilizada.										
ENUNCIADO										
Considerando um problema com 4 classes, assinale a alternativa que apresenta as quantidades de classificadores gerados usando respectivamente um-contra-todos e todos-contra-todos.										
ALTERNATIVAS										
A	4, 4.									
B	6, 4.									
C	4, 6. <table><tr><td>Estratégia</td><td>Fórmula</td><td>Resultado (N=4)</td></tr><tr><td>Um-contra-todos</td><td>N</td><td>4</td></tr><tr><td>Todos-contra-todos</td><td>$N(N-1)/2$</td><td>6</td></tr></table>	Estratégia	Fórmula	Resultado (N=4)	Um-contra-todos	N	4	Todos-contra-todos	$N(N-1)/2$	6
Estratégia	Fórmula	Resultado (N=4)								
Um-contra-todos	N	4								
Todos-contra-todos	$N(N-1)/2$	6								
D	6, 6.									


E	4, 2.
---	-------

Questão 10

As árvores de decisão são geradas por algoritmo de indução que leva em conta a importância do atributo na separação das classes do problema. Uma alternativa muito utilizada para estimar a importância de cada atributo consiste no cálculo do ganho de informação a partir do conceito de entropia. Nem todos os atributos do problema são utilizados na versão final da árvore.

ENUNCIADO

Dada a árvore de decisão abaixo que foi obtida a partir de base de treinamento contendo quatro atributos de entrada (x1, x2, x3 e x4) e duas classes possíveis (A e B).



Considerando a tabela abaixo como uma base de teste com três instâncias, indique a alternativa que apresenta a classe que será atribuída pela árvore às instâncias T1, T2 e T3, respectivamente.

Instâncias	x1	x2	x3	x4
T1	0	Verde	34	3
T2	0	Cinza	20	8
T3	1	Azul	5	10

ALTERNATIVAS

A	A, A, B.
B	B, B, A.
C	A, B, B.
D	B, A, B.

	x2 └ azul → x3 (<10 → B >=10 → A) └ verde → B (direta) └ cinza → x1 └ 0 → x3 (<10 → B >=10 → A) └ 1 → A └ 2 → B <table><tr><th>Instância</th><th>Caminho</th><th>Classe</th></tr><tr><td>T1</td><td>x2=Verde → B</td><td>B</td></tr><tr><td>T2</td><td>x2=Cinza → x1=0 → x3=20(≥10) → A</td><td>A</td></tr><tr><td>T3</td><td>x2=Azul → x3=5(<10) → B</td><td>B</td></tr></table>	Instância	Caminho	Classe	T1	x2=Verde → B	B	T2	x2=Cinza → x1=0 → x3=20(≥10) → A	A	T3	x2=Azul → x3=5(<10) → B	B
Instância	Caminho	Classe											
T1	x2=Verde → B	B											
T2	x2=Cinza → x1=0 → x3=20(≥10) → A	A											
T3	x2=Azul → x3=5(<10) → B	B											
E	B, B, B.												

Questão 11	
Com a evolução das redes neurais surgiram diversas funções de ativação para seus neurônios, cada uma com uma formulação matemática própria. O neurônio de uma rede neural artificial MLP (MúltiLayer Perceptron) possui uma função de ativação interna que recebe um somatório de entrada (soma ponderada das entradas do neurônio) e emite um valor de saída.	
ENUNCIADO	
Considerando a construção de um classificador MLP, assinale a alternativa que apresenta uma função de ativação que pode ser utilizada nos neurônios das camadas ocultas da rede para emitir valores entre -1 e 1.	
ALTERNATIVAS	
A	Softmax. (0, 1), mas normalizada de forma que a soma de todas as saídas seja 1 usada em camada de saída para classificação multiclasse, não em camadas ocultas.
B	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ Tangh.
C	Threshold. {0, 1} saída binária, não contínua nem no intervalo -1 a 1.
D	Relu. [0, +∞) só produz valores não-negativos, sem limite superior.
E	Sigmóide. (0, 1) — sempre positiva, não alcança valores negativos.

Questão 12

Na tarefa supervisionada de classificação, a matriz de confusão é uma importante ferramenta que nos permite uma análise detalhada dos erros de um classificador. Nela é possível conhecer onde ocorrem as confusões do modelo criado, ou seja, onde este erra com mais frequência.

ENUNCIADO

Analise a matriz de confusão abaixo, a qual foi obtida a partir da saída de um classificador utilizando N exemplos de teste.

	0	1	2	3	4	5	6	7	8	9
0	57	0	2	0	0	1	0	0	0	0
1	1	29	23	0	0	2	1	2	2	0
2	2	1	47	0	0	3	0	4	2	1
3	1	1	18	11	0	2	1	18	5	3
4	0	0	2	0	55	1	1	1	0	0
5	4	1	6	1	1	38	0	5	2	2
6	0	0	3	0	3	0	53	1	0	0
7	5	0	7	0	0	1	1	44	2	0
8	0	0	13	0	0	6	0	8	26	7
9	0	1	14	0	0	2	0	1	0	42

Com base na análise realizada, avalie as afirmativas abaixo:

AFIRMATIVAS

- I. O classificador lida com um problema de dez classes. **Verdadeira.** Matriz 10×10 (classes de 0 a 9).
- II. O número de exemplos classificados corretamente é 402. **Verdadeira.** Somando a diagonal principal (acertos): $57+29+47+11+55+38+53+44+26+42 = 402$
- III. O número de exemplos classificados é igual a 600. **Verdadeira** Todas as linhas somam 60 → Total = $10 \times 60 = 600$ exemplos
- IV. A classe 3 é a que apresenta a maior taxa de erro. **Verdadeira** Classe 3 tem a maior taxa de erro (81,7%)
- V. A classe 0 é a classe com menor taxa de erro. **Verdadeira** Classe 0 tem a menor taxa de erro (5,0%)

Classe	Soma da linha
0	$57+0+2+0+0+1+0+0+0+0 = 60$
1	$1+29+23+0+0+2+1+2+2+0 = 60$
2	$2+1+47+0+0+3+0+4+2+1 = 60$
3	$1+1+18+11+0+2+1+18+5+3 = 60$
4	$0+0+2+0+55+1+1+1+0+0 = 60$
5	$4+1+6+1+1+38+0+5+2+2 = 60$
6	$0+0+3+0+3+0+53+1+0+0 = 60$
7	$5+0+7+0+0+1+1+44+2+0 = 60$
8	$0+0+13+0+0+6+0+8+26+7 = 60$
9	$0+1+14+0+0+2+0+1+0+42 = 60$

Classe	Erros	Taxa de erro
0	$60-57=3$	5,0% ← menor
1	$60-29=31$	51,7%
2	$60-47=13$	21,7%
3	$60-11=49$	81,7% ← maior
4	$60-55=5$	8,3%
5	$60-38=22$	36,7%
6	$60-53=7$	11,7%
7	$60-44=16$	26,7%
8	$60-26=34$	56,7%
9	$60-42=18$	30,0%

É correto o que se afirma apenas em:

ALTERNATIVAS


A	I.
B	I e II.
C	I, II e III.
D	I, II e V.
E	I, II, III, IV e V.

Questão 13

A tarefa não supervisionada de agrupamento nos permite encontrar grupos (cluster) de dados similares a partir dos quais podemos descrever o problema, ou ainda, considerar os grupos encontrados como classes de um futuro classificador. A avaliação da tarefa de agrupamento é realizada com base em medidas como dispersão intra e inter grupos, ou ainda, índice silhueta.

ENUNCIADO

Os gráficos abaixo, disponíveis no site do framework de Aprendizagem de Máquina Scikit Learn, são resultados de um processo de agrupamento. No gráfico da esquerda temos três barras que correspondem aos índices silhueta de cada um dos grupos presentes no gráfico da direita (0-preto, 1-azul e 2-verde).




Fonte: Disponível em: <<https://scikit-learn.org/>>. Acesso em: 01 abr. 2020

A partir da análise do índice silhueta de cada grupo, analise as afirmativas abaixo:

AFIRMATIVAS	
I.	O grupo 0 (preto) apresenta o pior índice silhueta, inferior ao valor médio. Verdadeira
II.	O grupo 1 (azul) tem o melhor índice silhueta e é menor que o preto em termos de quantidade de instâncias. Verdadeira
III.	O valor médio da silhueta para estes 3 grupos é inferior a 0.6. Verdadeira
IV.	Fica evidente a necessidade de investigar a qualidade de agrupamentos considerando 2 e 4 grupos. Verdadeira
V.	A parte negativa do grupo 0 (preto) no gráfico da esquerda, corresponde às instâncias que estão próximas ao centróide do grupo. Falsa. Silhueta negativa significa o oposto: a instância está mais distante do seu próprio cluster (do seu centróide) do que do <i>cluster</i> vizinho — ou seja, provavelmente está na fronteira ou até "vazou" para o território de outro cluster. Instâncias próximas ao centróide teriam silhueta alta e positiva (bem encaixadas), não negativa.
É correto o que se afirma apenas em:	
ALTERNATIVAS	
A	I.
B	I e II.
C	I, II, III e IV.
D	I, II e V.
E	I, II, III, IV e V.

Questão 14
As máquinas de vetor de suporte (SVM, do inglês Support Vector Machines) podem ser utilizadas tanto para classificação quanto para regressão. Originalmente binário, um classificador baseado em SVM define um <i>hiperplano</i> entre as classes do problema com base em vetores de suporte que maximizam a distância (margem) entre elas.
ENUNCIADO
A figura abaixo apresenta o hiperplano definido por um SVM para a separação das duas classes do exemplo (bolas vermelhas e quadrados azuis). Ainda é possível observar nesta figura, a margem que foi definida entre as classes, os vetores de suporte de cada classe e alguns pontos situados entre as margens (neste exemplo, apenas um de cada classe).



Considerando a figura acima e o conceito de SVM, analise as afirmativas abaixo:

AFIRMATIVAS

- I. Os pontos na região entre as margens são considerados erros. **Verdadeira** Em um SVM de margem suave, pontos que violam a margem (mesmo que ainda do lado correto do hiperplano) recebem uma variável de folga (*slack*, $\xi > 0$) — são tratados como violações que o modelo aceita tolerar, mediante uma penalidade no treinamento.
- II. O algoritmo de treinamento do SVM busca maximizar a margem entre as classes. **Verdadeira**. Princípio fundamental do SVM: encontrar o hiperplano que **maximiza a distância** (margem) entre as classes, apoiado nos vetores de suporte — os pontos mais próximos da fronteira de decisão.
- III. O SVM somente pode ser aplicado para problemas de classificação binários. **Falsa**. SVM pode ser estendido para problemas multiclasse via estratégias um-contra-todos ou todos-contra-todos.
- IV. O SVM da figura pode ser chamado de margem soft por aceitar erros entre as margens. **Verdadeira**. A existência de pontos que violam a margem (um de cada classe, conforme mostrado) é exatamente o que caracteriza um SVM de **margem suave (soft margin)**, em contraste com o SVM de margem rígida (*hard margin*), que exige separação perfeita sem nenhuma violação.
- V. O parâmetro de relaxamento (C) do algoritmo de treinamento do SVM está relacionado à aceitação de erro durante o treinamento. **Verdadeira**. O hiper parâmetro **C** controla o *trade-off* entre maximizar a margem e minimizar as violações (erros) de classificação: valores altos de C penalizam fortemente violações (aproximando-se de margem rígida), enquanto valores baixos de C toleram mais violações em favor de uma margem maior.

É correto o que se afirma apenas em:

ALTERNATIVAS

A	I, II e III.
B	I, II, III e IV.


C	I, II, IV e V.
D	II, III e V.
E	I, II, III, IV e V.

Questão 15

Há algoritmos de indução que são mais susceptíveis a decorar os dados durante o treinamento (*overtraining*). Nestes casos utilizamos estratégias que nos permitem evitar que isto aconteça. Este é o caso do processo de poda utilizado durante o treinamento de Árvores de Decisão, ou ainda, a parada precoce do treinamento no caso de Redes Neurais Artificiais.

ENUNCIADO

A Figura abaixo adaptada do livro *Pattern Classification* (Duda, Richard O.; Hart, Peter E.; Stork, David G. Pattern classification. 2 ed. New York: John Wiley & Sons, 2001. 654 p.) nos mostra o erro de uma rede neural (eixo y) ao longo das épocas (eixo x) de treinamento, calculado sobre as bases de treinamento, validação e teste. A base de validação é parte da base de treinamento não utilizada para ajuste dos pesos da rede. Cada época consiste em uma passada por todos os exemplos de treinamento. Considerando a facilidade com que redes neurais artificiais podem decorar a base de treinamento, qual seria a época mais adequada neste caso para encerrar o treinamento da rede? Justifique sua resposta.



RESPOSTA ESPERADA

A época mais adequada para encerrar o treinamento é por volta da época 5, correspondente ao ponto de mínimo da curva de erro de validação, antes que ela comece a subir novamente.

Observando as três curvas do gráfico:

- **Erro de treinamento (preto):** decresce **monotonicamente** ao longo de todas as épocas. Isso é esperado, já que a rede está ajustando seus pesos cada vez mais aos exemplos de treinamento, podendo eventualmente **decorá-los** (memorização/*overfitting*) em vez de aprender o padrão geral.
- **Erro de validação (vermelho escuro):** decresce junto com o treinamento até aproximadamente a **época 4-5**, atinge um mínimo, e então **começa a subir** — mesmo com o erro de treinamento continuando a cair. Esse ponto de inflexão é o sinal mais confiável de que a rede está deixando de generalizar e passando a

memorizar ruído específico da base de treinamento.

- **Erro de teste (vermelho claro):** acompanha uma tendência similar à validação, confirmando que a perda de generalização não é um artefato isolado da base de validação, mas reflete o desempenho real esperado em dados não vistos.

Embora a curva de validação apresente uma leve queda novamente por volta das épocas 6-7, essa oscilação não deve ser assumida como confiável durante o treinamento em tempo real, pois, quando a rede atinge a época 5, ainda não se sabe se a curva vai subir indefinidamente ou cair novamente mais adiante. O critério prático de parada precoce (*early stopping*) consiste em interromper o treinamento assim que o erro de validação para de melhorar de forma consistente (geralmente com uma janela de paciência de algumas épocas sem melhora), evitando o risco de continuar treinando sobre uma tendência de overfitting que só se confirma ainda mais claramente a partir da época 8 em diante (onde ambas as curvas de validação e teste voltam a subir de forma mais acentuada).

Questão 16

A técnica de Aprendizagem de Máquina baseada em instâncias mais conhecida é o KNN (K-Nearest Neighbors). O KNN pode ser utilizado em tarefas de classificação e regressão. Apesar de se mostrar robusta para vários problemas esta técnica tem como principal ponto fraco o alto custo computacional no momento operacional do modelo, ou seja, durante os testes.

ENUNCIADO

Considerando um KNN (K=3) utilizado para um problema de regressão com objetivo de estimar a idade de uma pessoa a partir da imagem da face. Dada uma imagem de teste x_t contendo a face de uma determinada pessoa seus k vizinhos mais próximos (similares em termos de características da face) na base de treinamento possuem as seguintes idades: 45, 38 e 39 anos. Demonstre como o KNN poderia atribuir uma idade a partir da face da imagem de teste x_t ?

RESPOSTA ESPERADA

Diferente do KNN aplicado à **classificação** (onde se usa votação majoritária entre os rótulos dos vizinhos, como visto na Questão 2), no KNN aplicado à **regressão** o valor alvo é numérico e contínuo — não existem "classes" para votar. Por isso, a estratégia padrão é calcular a **média aritmética** (ou, em variantes mais sofisticadas, uma média ponderada pela distância) dos valores-alvo dos K vizinhos mais próximos.

Com $K=3$ e os vizinhos apresentando idades **45, 38 e 39** anos:

$$\hat{y}(x_t) = \frac{45 + 38 + 39}{3} = \frac{122}{3} \approx 40,67 \text{ anos}$$

O KNN atribuiria à imagem de teste x_t a idade estimada de aproximadamente **40,67 anos** (podendo ser arredondada para 41 anos, dependendo da convenção adotada). Tanto em classificação quanto em regressão instâncias similares tendem a ter saídas similares (hipótese de suavidade local). Em classificação, "similar" é operacionalizado como "pertence à mesma classe" (daí a votação). Em regressão, como a saída é um valor contínuo e não há classes discretas para contar, a agregação natural que preserva essa noção de similaridade é a média dos valores numéricos observados na vizinhança, assumindo que a idade real da pessoa da imagem de teste deve estar próxima da idade média de rostos

com características faciais semelhantes.